TRƯỜNG ĐẠI HỌC CÔNG NGHỆ — ĐHQGHN

Ba đóng góp của luận văn và bằng chứng thực nghiệm

Điểm khác biệt • Kết quả đo • Tiếp thu góp ý Seminar

Hệ thống phát hiện Ransomware dựa trên Phân tích đa tầng, tích hợp Học tích cực & Kiểm chứng độ trung thực XAI

Lưu Văn Doanh | GVHD: PGS.TS. Trương Ninh Thuận

Báo cáo kết quả và phạm vi kiểm chứng sau Seminar

Kế thừa nền tảng; bổ sung ba cơ chế cụ thể

So sánh về phương pháp; không xếp hạng AUC giữa các nghiên cứu dùng dữ liệu khác nhau.

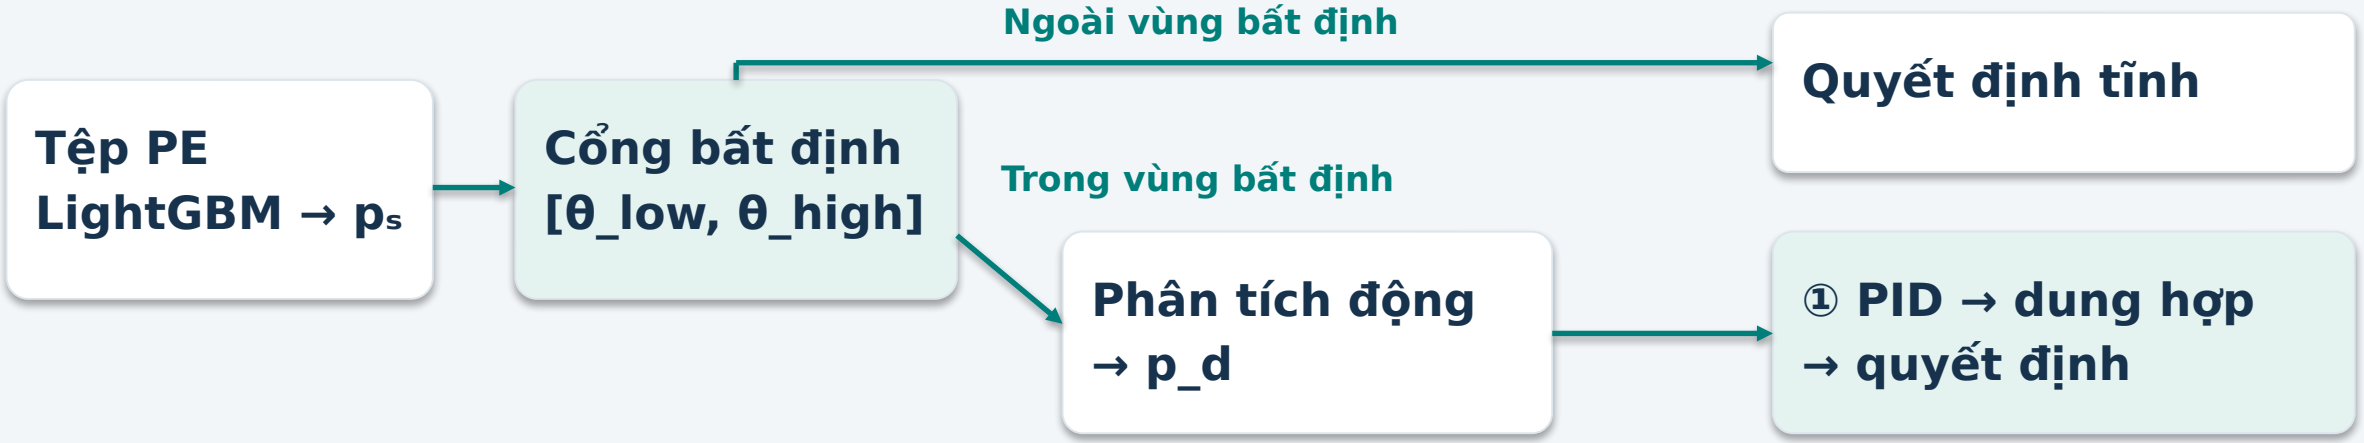
NỀN TẢNG KẾ THỪA	PHẦN LUẬN VĂN BỔ SUNG	BẰNG CHỨNG CẦN ĐO
EMBER / LightGBM **Anderson & Roth, 2018**	Dung hợp điểm tĩnh–động bằng trọng số có trạng thái, lấy cảm hứng từ PID.	Cùng hai tín hiệu: Fixed / P / PI / PID
AL + SHAP **Settles, 2009;** **Lundberg & Lee, 2017**	Chọn mẫu bằng bất định dự đoán, xung đột hướng và phương sai SHAP.	Cùng số nhãn: Random / U / XAI
Đánh giá giải thích **Yeh và cs., 2019**	Cụ thể hóa kiểm tra tác động, tương đồng và phân tách giải thích cho vector PE.	Top-SHAP / Random; độ nhạy và ràng buộc PE

Đóng góp ở cách thiết kế và kiểm chứng các thành phần; không coi PID, AL hay SHAP là thuật toán mới.

Nguồn: luuvan.pdf §2.4, §3.2–3.4; [2], [3], [14], [21], [27] trong tài liệu tham khảo.

Mỗi đóng góp tác động vào một khâu khác nhau

Cổng bất định quyết định chạy động; PID dung hợp; AL cập nhật mô hình; Fidelity kiểm tra giải thích.



② AL: mô hình → SHAP → chọn mẫu → oracle → huấn luyện lại trên toàn bộ nhãn tích lũy

③ Fidelity: kiểm tra giải thích của mô hình tĩnh

Cải thiện chọn nhãn, chất lượng phát hiện và chất lượng giải thích phải được đánh giá riêng.

Nguồn: luuvan.pdf §3.1–3.4; sơ đồ thiết kế được làm rõ sau Seminar.

PID bổ sung khả năng điều chỉnh trọng số có trạng thái

Lý do lựa chọn là giả thuyết kỹ thuật; hiệu quả giảm FPR cần phép đo ghép cặp.

Ý tưởng dung hợp

$$e_t = p_{s,t} - p_d,_t$$
$$u_t = K_p e_t + K_i \Sigma e + K_d \Delta e$$
$$w_t = \text{clip}(\text{sigmoid}(u_t), 0{,}1; 0{,}9)$$

$$p_final = w_t p_s + (1 - w_t) p_d$$
$$\Rightarrow p_final \in [0,1]$$

Vai trò và giới hạn

P: phản ứng với bất đồng hiện tại.
I: tích lũy bất đồng qua chuỗi.
D: phản ứng với biến thiên.

Bất đồng không cho biết mô hình nào đúng. Trọng số hợp lệ không bảo đảm AUC hoặc FPR tốt hơn.

Hiện đã có nguyên mẫu; chưa đủ bằng chứng thực nghiệm để kết luận PID cải thiện phát hiện.

Nguồn: luuvan.pdf §3.2, tr.36–39; src/pid_fusion.py. Chưa có kiểm chứng chất lượng bằng log động thật.

Pilot nhỏ, có đối chứng và lưu được dấu vết chạy

Huấn luyện mới trên CSV hiện có; không dùng mô hình đã huấn luyện sẵn để thay số trong luận văn.

2.000

Mẫu trong repository

2.381 đặc trưng
1.500 nhãn 0 / 500 nhãn 1

1.200 / 400 / 400

Train–pool / Val / Test

Split phân tầng cố định
Mọi ngưỡng chọn trên Val

5 × 5 × 6

Checkpoint AL

5 chiến lược × 5 seed
6 mức ngân sách: 200–700 nhãn

Chưa xác minh nguồn và ý nghĩa nhãn ransomware của CSV.
Đây là kiểm chứng nội bộ trên vector PE; chưa là đánh giá khái quát theo họ hoặc thời gian.

Nguồn: data/processed/real_mini_dataset.csv; cấu hình và split được lưu trong thư mục experiments/ của ZIP.

Dùng cấu trúc giải thích để xếp hạng mẫu cần nhãn

So với Uncertainty: bổ sung xung đột hướng và độ phân tán đóng góp của đặc trưng.

U — bất định

$$U = 1 - 2|p - 0{,}5|$$

Mẫu gần ranh giới dự đoán

H — hướng SHAP

$$H = -q_+ \log_2 q_+ - q_- \log_2 q_-$$

Hai hướng đóng góp cùng mạnh

V — phương sai

$$V = \mathrm{Var}(\varphi_1, \ldots, \varphi_d)$$

Đóng góp phân tán không đều

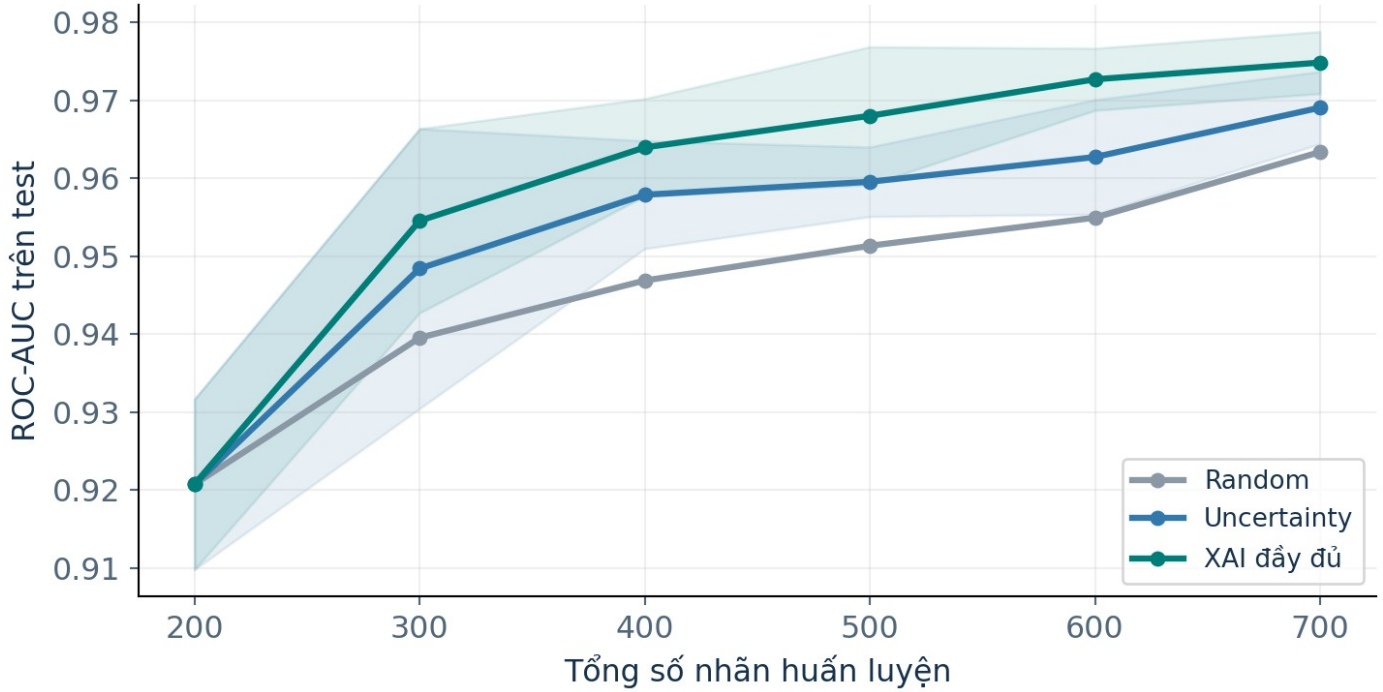
$$S = 0{,}3\hat{U} + 0{,}4\hat{H} + 0{,}3\hat{V}$$ | Min–max trên pool hiện tại

Ablation: Random • U • U+H • U+V • XAI đầy đủ — cùng số nhãn và cùng lịch học lại.

Nguồn: luuvan.pdf §3.3, Bảng 4.10; pilot_al/run_pilot.py. SHAP được tính lại bằng mô hình của từng vòng.

Cùng 700 nhãn: XAI vượt Uncertainty về AUC ở cả 5 seed

Trung bình ± độ lệch chuẩn qua 5 seed, dùng chung một tập test cố định.



ROC-AUC TẠI 700 NHÃN

0,9749 ± 0,0040

XAI đầy đủ

0,9691 ± 0,0046

Uncertainty

Δ AUC ghép cặp: +0,0058

Kết quả ủng hộ điểm chọn mẫu trong pilot; chưa suy ra tiết kiệm nhãn hay hiệu quả trên ransomware mới.

Nguồn: experiments/pilot_al/summary.json, metrics.csv và predictions.csv.gz; pilot, chưa xác minh nguồn CSV.

Kết hợp H và V cho AUC trung bình cao nhất; FPR còn biến động

Ngưỡng của từng mô hình chọn trên validation với TPR ≥ 95%; TPR test được báo riêng.

CHIẾN LƯỢC	AUC ± SD	FPR	TPR
Random	0,9634 ± 0,0063	21,73%	93,80%
U	0,9691 ± 0,0046	19,87%	95,60%
U + H	0,9676 ± 0,0031	17,20%	93,00%
U + V	0,9692 ± 0,0062	28,33%	96,40%
U + H + V	0,9749 ± 0,0040	17,53%	95,40%

Chi phí tính điểm

XAI: 31,7 ms/vòng
U: 2,7 ms/vòng

Pool 600–1.000 mẫu
2 CPU threads
Chưa gồm gán nhãn / học lại

FPR của XAI chỉ thấp hơn U ở 2/5 seed: chưa kết luận giảm cảnh báo nhầm ổn định.

Nguồn: pilot_al/metrics.csv và summary.json; số là trung bình 5 seed tại 700 nhãn, cùng test 400 mẫu.

Chuyển nguyên tắc XAI sang PE phải kiểm tra phép biến đổi

Pilot hiện kiểm tra vector đặc trưng; phần ràng buộc cấu trúc PE cần đánh giá tiếp.

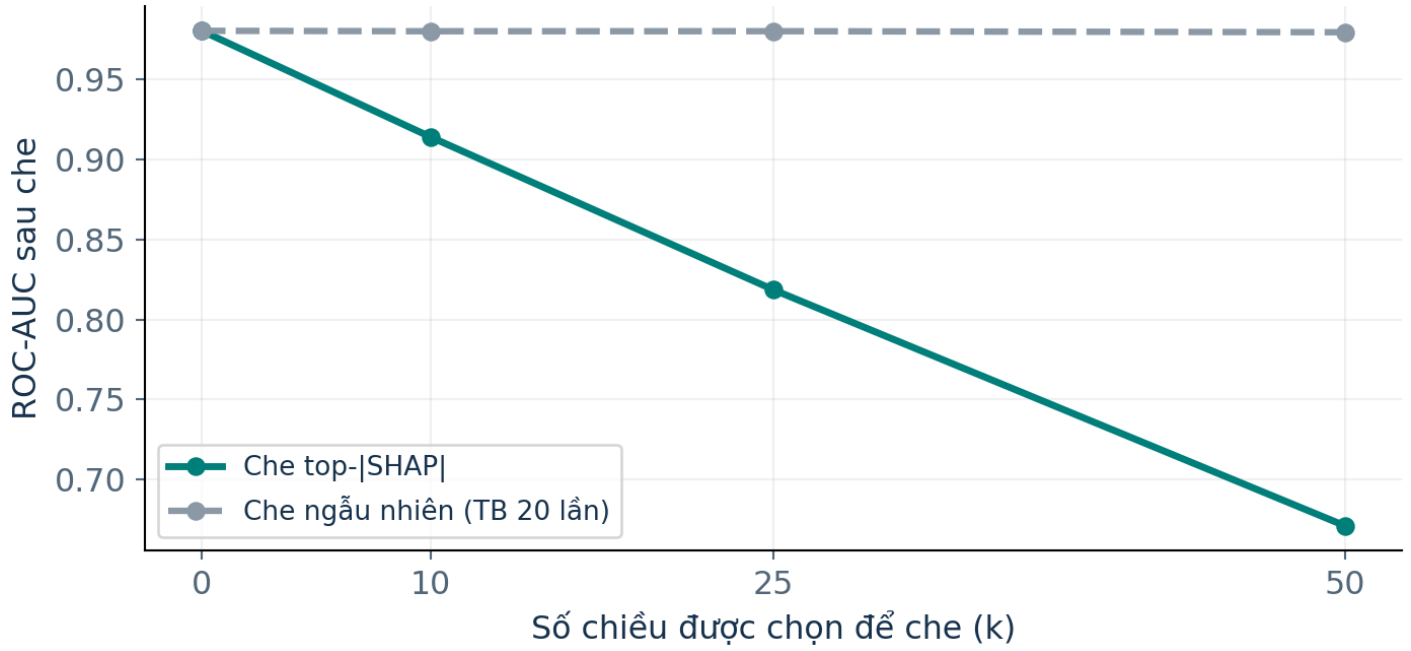
PHÉP KIỂM TRA	ĐIỀU CHỈNH / CẤU HÌNH ĐÃ CHẠY	KẾT LUẬN CHO PHÉP
Tác động đặc trưng	Che top-|SHAP| so với che ngẫu nhiên cùng k; baseline lấy từ train.	Thứ hạng SHAP liên quan đặc trưng mô hình sử dụng.
Tương đồng — EC	Tương quan cấu trúc tương đồng PE và SHAP; chuẩn hóa chỉ fit trên train.	Mức nhất quán với một định nghĩa khoảng cách cụ thể.
Phân tách — CF	Khoảng cách hai tâm SHAP, chuẩn hóa bằng chuẩn SHAP lớn nhất trong test.	Độ phân tách hai nhãn; không phải tính nhân quả.

Mean masking có thể phá quan hệ giữa trường PE; pilot chưa chứng minh “PE-aware” hoàn chỉnh.

Nguồn: luuvan.pdf §3.4, A.4; Yeh và cs. (2019); pilot_fidelity/run_pilot.py.

Che đặc trưng SHAP quan trọng gây suy giảm lớn hơn random

Mô hình mới: 1.200 mẫu train, test 400 mẫu; baseline trước che AUC = 0,9802.



Tại k = 25

Top-SHAP: 0,8185

Random: 0,9799

EC = 0,3044

CF = 0,5874

Không tổng hợp OFS

Kết quả hỗ trợ thứ hạng SHAP dưới phép che đã chọn; chưa chứng minh giải thích nhân quả.

Nguồn: pilot_fidelity/run_seed42/summary.json, mask_predictions.csv; random lặp 20 lần cho mỗi k.

Mỗi nhận xét được gắn với nội dung và bằng chứng cụ thể

“Đã mô tả” và “đã đo trong pilot” là hai mức hoàn thiện khác nhau.

HỘI ĐỒNG YÊU CẦU	ĐÃ LÀM / VỊ TRÍ	MỨC BẰNG CHỨNG HIỆN TẠI
Vì sao cần PID; có/không PID?	Giải thích vai trò, công thức, giới hạn §3.2, tr.36–39; slide 4.	Đã mô tả; còn thiếu điểm động thật và so Fixed / P / PI / PID.
XAI-AL tạo khác biệt gì?	Chạy 5 chiến lược × 5 seed Slide 6–8; pilot_al/.	Đã đo: AUC tăng ở cùng 700 nhãn; chưa chứng minh tiết kiệm nhãn.
Độ đo có phù hợp với PE?	Baseline train; đối chứng random §3.4; slide 9–10; pilot_fidelity/.	Đã đo masking vector; còn thiếu kiểm tra ràng buộc nhóm PE.
AUC tăng ít; chi phí thực tế?	Báo SD, AP, FPR/TPR và timing Slide 7–8; metrics.csv.	Có số đo pilot; chưa có latency end-to-end và chi phí chuyên gia.
Kết hợp cả hệ thống được gì?	Thiết kế ablation PID × AL Phụ lục C — slide 15.	Chưa đủ dữ liệu để đo tác động kết hợp; không dùng số giả lập.

Nguồn: góp ý.txt; luuvan.pdf (trang in); hai pilot thực nghiệm bổ sung kèm ZIP.

Đã có bằng chứng mới cho AL và kiểm tra SHAP

Mức kết luận bám theo thí nghiệm đã chạy; phần PID cần một gói đo bổ sung tập trung.

① PID Fusion

Nguyên mẫu có sẵn

Trọng số hợp lệ và
cơ chế có trạng thái.

**Cần điểm động thật +
đối chứng cùng đầu vào.**

② XAI-Guided AL

ΔAUC +0,0058

Cải thiện so với U
ở cả 5 seed của pilot.

**Chưa chứng minh giảm FPR
ổn định / tiết kiệm nhãn.**

③ Fidelity

AUC drop 0,1616

Top-SHAP k = 25 tác động
mạnh hơn random.

**Cần ràng buộc nhóm PE
và thống nhất công thức.**

Phần còn lại: xác minh nguồn dữ liệu → đo PID và bảng 2×2 → đồng bộ số liệu, công thức, code.

Nguồn: kết quả đã truy vết; kế hoạch đo bổ sung nằm ở Phụ lục C và báo cáo đánh giá bằng chứng.

Bảng 4.5 chưa đủ căn cứ dùng làm kết quả đã xác nhận

Các số dưới đây chỉ trích nguyên bản thảo; không phải kết quả tái chạy của đợt rà soát.

CẤU HÌNH	AUC	FPR	ĐỘ TRỄ GHI TRONG BẢNG
Static	0,9420	4,5%	2,1 ms — tĩnh
Dynamic	0,9915	0,2%	1.205,4 ms — động
Fixed-weight	0,9720	1,1%	16,4 ms — fusion
Gated	0,9760	1,0%	13,8 ms — fusion
PID	0,9818	0,8%	15,2 ms — fusion

Chưa dùng để khẳng định mức cải thiện

Script có kết quả gán sẵn.

Log demo sinh điểm động và độ trễ ngẫu nhiên.

Thiếu dự đoán từng mẫu và nguồn dữ liệu ghép cặp.

15,2 ms fusion không phải latency end-to-end; không so trực tiếp với 1.205,4 ms phân tích động.

Nguồn: luuvan.pdf Bảng 4.5, tr.53; scripts/run_experiments.py; scripts/live_defense_demo.py.

Các diễn giải cần sửa trước khi dùng lại số cũ

Không tự thay số chưa truy nguyên bằng AUC cao hơn từ mô hình có sẵn.

NỘI DUNG	SỐ ĐANG CÓ	KẾT LUẬN ĐÚNG PHẠM VI
AL và chi phí nhãn	AUC 0,9740 → 0,9818 2.000 → 2.500 nhãn	Không đủ suy ra tiết kiệm 90% nhãn. Cần so đường học đạt cùng mục tiêu.
Báo động nhầm	FP 135 → 48 trên 3.000 mẫu âm ⇒ FPR 4,5% → 1,6%	Không đồng nhất với FPR 0,8% của fusion khi chưa xác định đúng thí nghiệm.
Điểm OFS	Bảng: 0,3612; điều hòa từ FF/EC/CF được in:≈0,3640	Code dùng 0,5FF+0,3EC+0,2CF. Cần thống nhất cả định nghĩa thành phần.
Mô hình có sẵn	Kiểm tra trên 2.000 mẫu repo: AUC ≈0,9979	Không biết có trùng dữ liệu đã học. Không dùng làm số thay thế cho luận văn.

Nguồn: luuvan.pdf Bảng 4.6–4.9; results/fidelity_results.csv; model_check.json.

Tách tác động PID, AL và hệ thống kết hợp bằng bảng 2×2

Chỉ chạy sau khi có điểm động thực, đúng ID mẫu; mọi cấu hình dùng cùng ngân sách nhãn.

DUNG HỢP	RANDOM AL	XAI-GUIDED AL
Fixed-weight	F–R: đối chứng nền	F–X: tác động AL
PID	P–R: tác động PID	P–X: kết hợp

Nếu nói "cộng hưởng": cần kiểm tra tương tác
Δ = (M_PX − M_PR) − (M_FX − M_FR).

Gói đo tối thiểu

1. Cùng cặp p_s, p_d và nhãn.
2. Khóa gate, ngưỡng trên Val.
3. So Fixed / P / PI / PID.
4. Báo FPR–TPR, FP/FN, AUC và latency p50/p95.

Đầu vào cần: sample_id, split, label, p_static, p_dynamic, timestamp/session và thời gian đo thật.

OFS cần thống nhất miền giá trị trước khi tổng hợp

Đề xuất trước mắt: báo các thành phần riêng và đối chứng, chưa dùng OFS để xếp hạng chung.

ĐỘ ĐO	VẤN ĐỀ TOÁN HỌC	ĐIỀU CHỈNH VỪA ĐỦ
FF	Mean $\|p-p_{mask}\|/(p+\varepsilon)$ không bị chặn 1. Pilot k = 25 cho FF thô ≈2,0045.	Báo AUC drop và mean $\|\Delta p\|$ riêng; khóa lại định nghĩa nếu thay FF.
EC	Pearson r ∈[−1,1]; có thể âm. Không là “tỉ lệ giải thích đúng”.	Báo r, phép tương đồng và chuẩn hóa; không coi các cặp là độc lập.
CF	$\|\|C_1-C_0\|\|/\max\|\|\varphi\|\|$ có thể tới 2. Phân tách lớp không đồng nghĩa fidelity.	Báo như độ phân tách; nếu chuẩn hóa phải ghi công thức và lý do.
OFS	Trung bình điều hòa cần thành phần dương, cùng hướng và thang đo phù hợp.	Chưa tổng hợp khi miền chưa thống nhất; không clip hậu nghiệm để làm đẹp số.

Nguồn: luuvan.pdf công thức 3.15–3.18; src/fidelity_framework.py; pilot_fidelity/run_seed42/summary.json.

Số trên slide có cấu hình, dự đoán và log đi kèm

Hai pilot độc lập về mô hình; dùng chung split để dễ kiểm tra, không cộng gộp các mức cải thiện.

Dấu vết thí nghiệm

AL: 150 checkpoint / 12.500 truy vấn
120.000 dự đoán Val và Test.

Fidelity: 3 mức k × 20 random masks
Lưu model, SHAP, mask và dự đoán.

Cấu hình, split, seed, hash và mã chạy kèm ZIP.

Nghiên cứu kế thừa

Anderson & Roth (2018) — EMBER
Åström & Hägglund (2001) — PID
Lundberg & Lee (2017) — SHAP
Settles (2009) — Active Learning
Yeh và cs. (2019) — Infidelity / Sensitivity

Chưa có hash tệp PE, họ hoặc thời gian nguồn: split theo dòng chưa thay được kiểm chứng theo họ/thời gian.

Nguồn: ZIP kèm PowerPoint/PDF; dữ liệu đầu vào nằm tại doanhjut/thesis2026.